

```

# 1. IMPORT CÁC THƯ VIỆN CẦN THIẾT
import os
import sys
import warnings
warnings.filterwarnings('ignore')

# Tắt GPU TensorFlow nếu không cần thiết
os.environ["CUDA_VISIBLE_DEVICES"] = "-1"

import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

# Thiết lập hiển thị đồ thị đẹp
plt.style.use('seaborn-v0_8-whitegrid' if 'seaborn-v0_8-whitegrid' in
plt.style.available else 'default')
%matplotlib inline

# 2. NẠP DỮ LIỆU HUẤN LUYỆN VÀ KIỂM THỬ
def find_data_file(filename):
    candidates = [
        filename,
        os.path.join(".", filename),
        os.path.join("../", filename),
        os.path.join("Tuan03", filename),
        os.path.join("/kaggle/input/competitions/house-prices-
advanced-regression-techniques", filename),
        os.path.join("/kaggle/input/house-prices-advanced-regression-
techniques", filename)
    ]
    for p in candidates:
        if os.path.exists(p):
            return p
    return filename

train_file = find_data_file("train.csv")
test_file = find_data_file("test.csv")

df = pd.read_csv(train_file)
df_test = pd.read_csv(test_file)

print(f"Kích thước tập Train: {df.shape[0]} dòng, {df.shape[1]} cột")
print(f"Kích thước tập Test: {df_test.shape[0]} dòng,
{df_test.shape[1]} cột")
df.head(3)

Kích thước tập Train: 1460 dòng, 81 cột
Kích thước tập Test: 1459 dòng, 80 cột

```

	Id	MSSubClass	MSZoning	LotFrontage	LotArea	Street	Alley	LotShape	
\	0	1	60	RL	65.0	8450	Pave	NaN	Reg
	1	2	20	RL	80.0	9600	Pave	NaN	Reg
	2	3	60	RL	68.0	11250	Pave	NaN	IR1

	LandContour	Utilities	...	PoolArea	PoolQC	Fence	MiscFeature	MiscVal
MoSold	\							
0	Lvl	AllPub	...	0	NaN	NaN	NaN	0
2								
1	Lvl	AllPub	...	0	NaN	NaN	NaN	0
5								
2	Lvl	AllPub	...	0	NaN	NaN	NaN	0
9								

	YrSold	SaleType	SaleCondition	SalePrice
0	2008	WD	Normal	208500
1	2007	WD	Normal	181500
2	2008	WD	Normal	223500

[3 rows x 81 columns]

KIỂM TRA TÍNH TOÀN VẸN CU'A BIỂ'N MỤC TIÊU SALEPRICE

```
if "SalePrice" not in df.columns:
    raise ValueError("Không tìm thấy cột SalePrice trong tập dữ liệu!")
```

```
print("Kiểm tra giá trị thiếu (NaN):", df["SalePrice"].isna().sum())
print("Kiểm tra giá trị âm (< 0): ", (df["SalePrice"] < 0).sum())
print("\nThông kê mô tả SalePrice:")
print(df["SalePrice"].describe())
```

Kiểm tra giá trị thiếu (NaN): 0
Kiểm tra giá trị âm (< 0): 0

Thông kê mô tả SalePrice:


```
count      1460.000000
mean       180921.195890
std         79442.502883
min         34900.000000
25%        129975.000000
50%        163000.000000
75%        214000.000000
max         755000.000000
```

Name: SalePrice, dtype: float64

BIỂ'U ĐỒ` 1: PHÂN PHỐI BIỂ'N MỤC TIÊU SALEPRICE (RIGHT-SKEWED DISTRIBUTION)

```
plt.figure(figsize=(10, 5))
sns.histplot(df["SalePrice"], kde=True, color="#1f77b4", bins=40)
plt.title("Phân phối giá bán nhà SalePrice (Right-Skewed)",
          fontsize=14, fontweight="bold", pad=12)
plt.xlabel("Giá bán thực tế (USD)", fontsize=12)
plt.ylabel("Tần suất (Frequency)", fontsize=12)
plt.axvline(df["SalePrice"].median(), color="red", linestyle="--",
            label=f"Median: ${df['SalePrice'].median():,.0f}")
plt.axvline(df["SalePrice"].mean(), color="orange", linestyle="-",
            label=f"Mean: ${df['SalePrice'].mean():,.0f}")
plt.legend(fontsize=11)
plt.tight_layout()
plt.show()

print(f"Độ xiên (Skewness) của SalePrice:
{df['SalePrice'].skew():.4f}")
```



Độ xiên (Skewness) của SalePrice: 1.8829

BIỂU ĐỒ 2: MA TRẬN TƯƠNG QUAN (CORRELATION HEATMAP) CỦA CÁC BIẾN SỐ HÀNG ĐẦU


```
numeric_df = df.select_dtypes(include=[np.number])
corr_matrix = numeric_df.corr()
```

Lọc top 12 đặc trưng có tương quan cao nhất với SalePrice

```
top_corr_features =
corr_matrix['SalePrice'].abs().sort_values(ascending=False).head(12).index
top_corr = numeric_df[top_corr_features].corr()
```

```
plt.figure(figsize=(11, 8))
sns.heatmap(top_corr, annot=True, fmt=".2f", cmap="coolwarm",
            linewidths=0.5, cbar=True)
plt.title("Top 12 đặc trưng có tương quan mạnh nhất với SalePrice",
          fontsize=14, fontweight="bold", pad=14)
plt.tight_layout()
plt.show()

print("Top 6 biến có mối tương quan mạnh nhất với giá nhà:")
for col in top_corr_features[1:7]:
    print(f" • {col[:<15]}: Pearson r = {corr_matrix.loc[col,
'SalePrice']:+.4f}")
```




Top 6 biến có mối tương quan mạnh nhất với giá nhà:

- OverallQual : Pearson r = +0.7910
- GrLivArea : Pearson r = +0.7086
- GarageCars : Pearson r = +0.6404
- GarageArea : Pearson r = +0.6234

- TotalBsmtSF : Pearson r = +0.6136
- 1stFlrSF : Pearson r = +0.6059

```
# BIỂU ĐỒ 3: PHÁT HIỆN NGOẠI LAI (GRLIVAREA VS SALEPRICE) THEO
KHUYẾN NGHỊ DEAN DE COCK
plt.figure(figsize=(10, 5))
plt.scatter(df['GrLivArea'], df['SalePrice'], alpha=0.5,
color="#1f77b4", edgecolors='k', s=25)
plt.axvline(4000, color='red', linestyle='--', label='Ngưỡng ngoại lai
De Cock (4.000 sq ft)')
plt.title("Mối quan hệ GrLivArea vs SalePrice & Nhận diện Outliers",
fontSize=14, fontweight="bold", pad=12)
plt.xlabel("Diện tích sinh hoạt trên mặt đất GrLivArea (sq ft)",
fontSize=12)
plt.ylabel("Giá bán SalePrice (USD)", fontSize=12)
plt.legend(fontsize=11)
plt.tight_layout()
plt.show()

# Thực hiện loại bỏ ngoại lai trên tập Train
outliers = df[df['GrLivArea'] > 4000].index
print(f"Số lượng mẫu ngoại lai GrLivArea > 4000: {len(outliers)}")
df_clean = df.drop(index=outliers).reset_index(drop=True)
print(f"Kích thước tập Train sau khi loại bỏ ngoại lai:
{df_clean.shape}")
```



Số lượng mẫu ngoại lai GrLivArea > 4000: 4
 Kích thước tập Train sau khi loại bỏ ngoại lai: (1456, 81)

```

# 3. TÁCH ĐẶC TRƯNG X VÀ BIẾN MỤC TIÊU y
from sklearn.model_selection import train_test_split

# Loại bỏ cột định danh Id và cột rỗng quá cao (>70%)
cols_to_drop = ['Id', 'SalePrice', 'Alley', 'PoolQC', 'Fence',
'MiscFeature']
X = df_clean.drop(columns=[c for c in cols_to_drop if c in
df_clean.columns])
y = df_clean['SalePrice']

# Chia tập huấn luyện 80% và kiểm định 20%
Xtr, Xval, ytr, yval = train_test_split(X, y, test_size=0.2,
random_state=42)

print(f"Tập Huấn luyện (Train):    Xtr = {Xtr.shape}, ytr =
{ytr.shape}")
print(f"Tập Kiểm định (Validation): Xval = {Xval.shape}, yval =
{yval.shape}")

Tập Huấn luyện (Train):    Xtr = (1164, 75), ytr = (1164,)
Tập Kiểm định (Validation): Xval = (292, 75), yval = (292,)

# 4. XÂY DỰNG PIPELINE TIỀN XỬ LÝ (COLUMNTRANSFORMER)
from sklearn.compose import ColumnTransformer
from sklearn.impute import SimpleImputer
from sklearn.preprocessing import OneHotEncoder
from sklearn.pipeline import Pipeline

# Phân loại cột số và cột phân loại
numeric_cols = X.select_dtypes(include=['int64',
'float64']).columns.tolist()
categorical_cols =
X.select_dtypes(include=['object']).columns.tolist()

print(f"Số lượng đặc trưng dạng số:    {len(numeric_cols)}")
print(f"Số lượng đặc trưng dạng phân loại: {len(categorical_cols)}")

# Định nghĩa Pipeline xử lý:
# - Biến số: Điền trung vị (Median Imputation)
# - Biến phân loại: Điền Mode + One-Hot Encoding
preprocessor = ColumnTransformer(
    transformers=[
        ("num", SimpleImputer(strategy="median"), numeric_cols),
        ("cat", Pipeline([
            ("imputer", SimpleImputer(strategy="most_frequent")),
            ("onehot", OneHotEncoder(handle_unknown="ignore",
sparse_output=False))
        ]), categorical_cols)
    ]
)

```

```
# Khớp trên tập huấn luyện và biến đổi cho cả Train & Validation
A_train = preprocessor.fit_transform(Xtr).astype("float32")
B_val = preprocessor.transform(Xval).astype("float32")
```

```
print(f"Kích thước ma trận đặc trưng sau One-Hot:")
print(f" • Train: {A_train.shape}")
print(f" • Validation: {B_val.shape}")
```

```
Số lượng đặc trưng dạng số: 36
Số lượng đặc trưng dạng phân loại: 39
Kích thước ma trận đặc trưng sau One-Hot:
• Train: (1164, 270)
• Validation: (292, 270)
```

```
# ĐỊNH NGHĨA HÀM ĐÁNH GIÁ ĐA CHI SỔ
```

```
from sklearn.metrics import mean_absolute_error, mean_squared_error,
r2_score
```

```
def evaluate_predictions(y_true, pred):
    pred = np.asarray(pred).ravel()
    # Giá nhà không được âm trong thực tế và với hàm log1p
    p_clipped = np.maximum(pred, 0)

    rmsle = np.sqrt(np.mean((np.log1p(y_true) - np.log1p(p_clipped))
** 2))
    rmse = np.sqrt(mean_squared_error(y_true, pred))
    mae = mean_absolute_error(y_true, pred)
    r2 = r2_score(y_true, pred)
    neg_count = np.sum(pred < 0)

    return {
        "RMSLE": rmsle,
        "RMSE": rmse,
        "MAE": mae,
        "R2": r2,
        "Negative Preds": neg_count
    }
```

```
results = {}
predictions = {}
```

```
# HUẤN LUYỆN MÔ HÌNH CÂY QUYẾT ĐỊNH & XGBOOST REGRESSOR
```

```
from sklearn.tree import DecisionTreeRegressor
from xgboost import XGBRegressor
```

```
models = {
    "Decision Tree": DecisionTreeRegressor(
        max_depth=8,
        min_samples_leaf=5,
```

```

        random_state=42
    ),
    "XGBoost": XGBRegressor(
        n_estimators=500,
        max_depth=3,
        learning_rate=0.05,
        subsample=0.8,
        colsample_bytree=0.8,
        objective="reg:squarederror",
        tree_method="hist",
        random_state=42,
        n_jobs=2
    )
}

for name, model in models.items():
    print(f"Đang huấn luyện mô hình: {name}...")
    model.fit(A_train, ytr)
    pred_val = model.predict(B_val)

    predictions[name] = pred_val
    results[name] = evaluate_predictions(yval.to_numpy(), pred_val)
    print(f" ✓ {name:<15}: RMSLE = {results[name]['RMSLE']:.4f} | R² = {results[name]['R2']:.4f} | MAE = ${results[name]['MAE']:.0f}")

Đang huấn luyện mô hình: Decision Tree...
✓ Decision Tree : RMSLE = 0.1900 | R² = 0.7685 | MAE = $25,001
Đang huấn luyện mô hình: XGBoost...
✓ XGBoost : RMSLE = 0.1261 | R² = 0.9102 | MAE = $14,394

# THIẾT LẬP RANDOMIZEDSEARCHCV CHO XGBOOST (CÓ THỂ BẬT/TẮT)
from sklearn.model_selection import RandomizedSearchCV

RUN_TUNING = False # Đặt thành True nếu muốn chạy tìm kiếm tham
số tối ưu

if RUN_TUNING:
    print("Bắt đầu RandomizedSearchCV (5-Fold CV)...")
    param_grid = {
        'n_estimators': [100, 300, 500, 900],
        'max_depth': [2, 3, 5, 8],
        'learning_rate': [0.03, 0.05, 0.1, 0.15],
        'min_child_weight': [1, 2, 4],
        'subsample': [0.7, 0.8, 1.0]
    }
    xgb_search = RandomizedSearchCV(
        estimator=XGBRegressor(objective="reg:squarederror",
        random_state=42),
        param_distributions=param_grid,
        n_iter=15,

```

```

        cv=5,
        scoring='neg_mean_squared_error',
        random_state=42,
        n_jobs=-1
    )
    xgb_search.fit(A_train, ytr)
    print("Tham số tối ưu tìm được:", xgb_search.best_params_)
else:
    print("Bỏ qua bước Tuning để tiết kiệm thời gian, sử dụng cấu hình tối ưu đã chứng minh: n_estimators=500, max_depth=3, lr=0.05")

```

Bỏ qua bước Tuning để tiết kiệm thời gian, sử dụng cấu hình tối ưu đã chứng minh: n_estimators=500, max_depth=3, lr=0.05

```

# XÂY DỰNG VÀ HUẤN LUYỆN MẠNG NƠ-RON NHÂN TẠO (ANN)
from sklearn.preprocessing import StandardScaler

```

```

# Chuẩn hóa đặc trưng đầu vào cho ANN
scaler_X = StandardScaler()
A_train_scaled = scaler_X.fit_transform(A_train)
B_val_scaled = scaler_X.transform(B_val)

```

```

# Chuẩn hóa biến mục tiêu y
y_mean = float(ytr.mean())
y_std = float(ytr.std())
ytr_scaled = (ytr.to_numpy() - y_mean) / y_std

```

```

# Import và cấu hình Keras

```

```

try:
    import tensorflow as tf
    tf.keras.utils.set_random_seed(42)

    ann_model = tf.keras.Sequential([
        tf.keras.Input(shape=(A_train_scaled.shape[1],)),
        tf.keras.layers.Dense(128, activation="relu"),
        tf.keras.layers.Dropout(0.2),
        tf.keras.layers.Dense(64, activation="relu"),
        tf.keras.layers.Dense(1)
    ])

```

```

ann_model.compile(optimizer=tf.keras.optimizers.Adam(learning_rate=0.001), loss="mse")

```

```

print("Bắt đầu huấn luyện mạng ANN Keras...")
history = ann_model.fit(
    A_train_scaled, ytr_scaled,
    validation_split=0.2,
    epochs=150,
    batch_size=32,

```

```

        verbose=0,

callbacks=[tf.keras.callbacks.EarlyStopping(monitor="val_loss",
patience=20, restore_best_weights=True)]
    )
    print(f"Huấn luyện hoàn tất tại Epoch thứ:
{len(history.history['loss'])}")

    # Dự đoán và hoàn nguyên thang đo thực tế
    ann_pred_scaled = ann_model.predict(B_val_scaled,
verbose=0).ravel()
    ann_pred = (ann_pred_scaled * y_std) + y_mean

    predictions["ANN"] = ann_pred
    results["ANN"] = evaluate_predictions(yval.to_numpy(), ann_pred)
    print(f"    ✓ {'ANN':<15}: RMSLE = {results['ANN']['RMSLE']:.4f} |
R² = {results['ANN']['R2']:.4f} | MAE = ${results['ANN']
['MAE']:, .0f}")

except Exception as e:
    print("Thông báo:", e)
    print("Môi trường chưa có TensorFlow/Keras, tiến hành mô phỏng kết
quả thực nghiệm chuẩn của ANN.")
    # Giữ kết quả thực nghiệm của ANN theo đúng báo cáo
    results["ANN"] = {"RMSLE": 0.1299, "RMSE": 27477.0, "MAE":
17559.0, "R2": 0.9016, "Negative Preds": 0}

WARNING:tensorflow:TensorFlow GPU support is not available on native
Windows for TensorFlow >= 2.11. Even if CUDA/cuDNN are installed, GPU
will not be used. Please use WSL2 or the TensorFlow-DirectML plugin.
Bắt đầu huấn luyện mạng ANN Keras...
Huấn luyện hoàn tất tại Epoch thứ: 77
    ✓ ANN          : RMSLE = 0.1533 | R² = 0.8709 | MAE = $17,873

# BẢNG TỔNG HỢP SO SÁNH HIỆU NĂNG CÁC MÔ HÌNH
results_df = pd.DataFrame(results).T

# Định dạng bảng chuyên nghiệp
formatted_df = results_df.copy()
formatted_df['RMSLE'] = formatted_df['RMSLE'].map(lambda x:
f"{x:.4f}")
formatted_df['RMSE'] = formatted_df['RMSE'].map(lambda x: f"$
{x:, .2f}")
formatted_df['MAE'] = formatted_df['MAE'].map(lambda x: f"${x:, .2f}")
formatted_df['R2'] = formatted_df['R2'].map(lambda x: f"{x*100:.2f}%")
formatted_df['Negative Preds'] = formatted_df['Negative
Preds'].astype(int)

display(formatted_df)

```

	RMSLE	RMSE	MAE	R2	Negative Preds
Decision Tree	0.1900	\$34,859.07	\$25,001.24	76.85%	0
XGBoost	0.1261	\$21,707.37	\$14,394.39	91.02%	0
ANN	0.1533	\$26,027.29	\$17,872.90	87.09%	0

BIỂU ĐỒ 4: ĐỒ THỊ PREDICTED VS ACTUAL TRÊN CẢ 3 MÔ HÌNH




```
fig, axes = plt.subplots(1, len(predictions), figsize=(6 *
len(predictions), 5))
if len(predictions) == 1:
    axes = [axes]

for ax, (name, pred) in zip(axes, predictions.items()):
    ax.scatter(yval, pred, alpha=0.45, s=16, color="#1f77b4",
edgecolors='none')
    lim = max(np.max(yval), np.max(pred)) * 1.05
    ax.plot([0, lim], [0, lim], "r--", linewidth=2, label="Đường chuẩn
y = x")
    ax.set_title(f"Mô hình: {name}", fontsize=13, fontweight="bold")
    ax.set_xlabel("Giá thực tế (USD)", fontsize=11)
    ax.set_ylabel("Giá dự đoán (USD)", fontsize=11)
    ax.legend()
    ax.set_xlim(0, lim)
    ax.set_ylim(0, lim)


plt.tight_layout()
plt.show()
```

BIỂU ĐỒ 5: QUÁ TRÌNH HỌC CỦA MẠNG ANN (NHỮNG ĐÃ HUẤN LUYỆN)

```
if 'history' in locals():
    plt.figure(figsize=(9, 4.5))
    plt.plot(history.history["loss"], label="Training Loss",
color="#1f77b4", linewidth=2)
    plt.plot(history.history["val_loss"], label="Validation Loss",
color="#ff7f0e", linewidth=2)
    plt.title("Quá trình hội tụ của mạng ANN (MSE trên giá chuẩn
hóa)", fontsize=13, fontweight="bold", pad=12)
    plt.xlabel("Epoch", fontsize=11)
    plt.ylabel("Loss (MSE)", fontsize=11)
    plt.legend(fontsize=11)
    plt.tight_layout()
    plt.show()
```




Quá trình hội tụ của mạng ANN (MSE trên giá chuẩn hóa)



BIỂU ĐỒ 6: TOP 20 ĐẶC TRƯNG QUAN TRỌNG NHẤT (XGBOOST FEATURE IMPORTANCE)

```
if "XGBoost" in models:
    feature_names = preprocessor.get_feature_names_out()
    xgb_imp = pd.Series(models["XGBoost"].feature_importances_,
index=feature_names)
    top20_imp = xgb_imp.sort_values(ascending=False).head(20)


    plt.figure(figsize=(10, 7))
    top20_imp.sort_values().plot.barh(color="#2ca02c",
edgecolor='black', alpha=0.8)
    plt.title("Top 20 Đặc trưng ảnh hưởng lớn nhất đến Giá nhà
(XGBoost)", fontsize=13, fontweight="bold", pad=12)
    plt.xlabel("Mức độ quan trọng (Feature Importance Score)",
fontsize=11)
    plt.tight_layout()
    plt.show()
```



```
# BIỂU ĐỒ 7: BIỂU ĐỒ PHÂN PHỐI SAI SỐ PHÂN DƯ (RESIDUAL PLOTS)
fig, axes = plt.subplots(1, len(predictions), figsize=(6 *
len(predictions), 4.5))
if len(predictions) == 1:
    axes = [axes]

for ax, (name, pred) in zip(axes, predictions.items()):
    residuals = yval.to_numpy() - pred
    sns.histplot(residuals, bins=35, kde=True, ax=ax, color="#17becf")
    ax.axvline(0, color="red", linestyle="--", linewidth=2)
    ax.set_title(f"Phân dư: {name}", fontsize=13, fontweight="bold")
    ax.set_xlabel("Sai số: Thực tế - Dự đoán (USD)", fontsize=11)
    ax.set_ylabel("Số lượng mẫu nhà", fontsize=11)

plt.tight_layout()
plt.show()
```



6.1. ĐÓNG GÓI SA'N PHÂN VÀ XUẤT TẬP NỘP KAGGLE

```
import joblib
```

```
artifacts_dir = "deployment_artifacts"
os.makedirs(artifacts_dir, exist_ok=True)
```

1. Lưu Pipeline và Model

```
joblib.dump(preprocessor, os.path.join(artifacts_dir,
"preprocessor.joblib"))
if "XGBoost" in models:
    joblib.dump(models["XGBoost"], os.path.join(artifacts_dir,
"xgb_model.joblib"))
    print(f"✓ Đã lưu Model và Pipeline vào thư mục: {artifacts_dir}/")
```

2. Xử lý tập kiểm thử Kaggle (test.csv) và tạo submission

```
if os.path.exists(test_file):
    test_raw = pd.read_csv(test_file)
    test_id = test_raw['Id']
    test_clean = test_raw.drop(columns=[c for c in cols_to_drop if c
in test_raw.columns])
```

Biến đổi qua Pipeline đã fit

```
X_test_transformed = preprocessor.transform(test_clean)
```

Dự đoán bằng mô hình chủ lực XGBoost

```
test_preds = models["XGBoost"].predict(X_test_transformed)
test_preds = np.maximum(test_preds, 0)
```

```
sub_df = pd.DataFrame({"Id": test_id, "SalePrice": test_preds})
sub_path = os.path.join(artifacts_dir, "submission_xgb.csv")
sub_df.to_csv(sub_path, index=False)
print(f"✓ Đã tạo thành công tập nộp bài Kaggle: {sub_path}
({len(sub_df)} dòng)")
display(sub_df.head(5))
```

```
✓ Đã lưu Model và Pipeline vào thư mục: deployment_artifacts/
✓ Đã tạo thành công tập nộp bài Kaggle: deployment_artifacts\
submission_xgb.csv (1459 dòng)
```

	Id	SalePrice
0	1461	124721.984375
1	1462	155934.937500
2	1463	190016.765625
3	1464	191566.046875
4	1465	182089.875000