ĐỀ XUẤT ĐỀ TÀI CUỐI KỲ MÔN MÁY HỌC (PROPOSAL)

TÊN ĐỀ TÀI: DỰ ĐOÁN NGUY CƠ BỎ HỌC VÀ KẾT QUẢ HỌC TẬP CỦA SINH VIÊN DỰA TRÊN DỮ LIỆU ĐA CHIỀU (PREDICT STUDENTS' DROPOUT AND ACADEMIC SUCCESS)

1. Thông tin nhóm (Nhóm 10)

STT	Họ và tên	MSSV	Vai trò	Phân công nhiệm vụ dự kiến
1	Dương Gia Phát	3124411212	Nhóm trưởng	Quản lý tiến độ chung; Thiết kế pipeline thực nghiệm; Xây dựng mô hình Baseline (Logistic Regression), tinh chỉnh siêu tham số và phân tích kết quả; Tổng hợp báo cáo cuối kỳ.
2	Văn Nguyễn Thành Đạt	3124411067	Thành viên	Khám phá dữ liệu (EDA), trực quan hóa phân phối dữ liệu và mối tương quan giữa các biến; Nghiên cứu và huấn luyện mô hình Decision Tree.
3	Lê Văn Hiếu	3124411091	Thành viên	Nghiên cứu và huấn luyện mô hình SVM (Support Vector Machine); Xây dựng ứng dụng minh họa (Demo Web App bằng Streamlit); Chuẩn bị slide thuyết trình.
4	Cái Trần Minh Tiến	3124411309	Thành viên	Tiền xử lý dữ liệu (Data Cleaning, Scaling, Encoding), xử lý mất cân bằng dữ liệu (SMOTE/Class Weight) và lựa chọn đặc trưng; Nghiên cứu và huấn luyện mô hình Random Forest.

2. Giới thiệu bài toán

Bối cảnh: Trong giáo dục đại học, tình trạng sinh viên bỏ học giữa chừng (Dropout) là một trong những thách thức lớn đối với các cơ sở đào tạo. Việc bỏ học không chỉ gây lãng phí nguồn lực tài chính, thời gian của bản thân sinh viên và gia đình mà còn ảnh hưởng trực tiếp đến chỉ số chất lượng đào tạo và uy tín của nhà trường.

Lý do lựa chọn: Với sự phát triển của hệ thống quản lý đào tạo số hóa, dữ liệu về nhân khẩu học, hoàn cảnh kinh tế - xã hội và kết quả học tập ở các học kỳ đầu của sinh viên được lưu trữ rất đầy đủ. Việc ứng dụng các thuật toán Máy học (Machine Learning) để khai thác nguồn dữ liệu này giúp phát hiện sớm các dấu hiệu bất thường mà phương pháp thống kê truyền thống khó nhận diện toàn diện.

Ý nghĩa thực tiễn: Hệ thống dự đoán đóng vai trò như một công cụ cảnh báo sớm (Early Warning System), hỗ trợ ban cố vấn học tập và phòng công tác sinh viên kịp thời nhận diện những sinh viên có nguy cơ bỏ học cao ngay sau năm nhất. Từ đó, nhà trường có thể đưa ra các biện pháp can thiệp, tư vấn tâm lý, hỗ trợ học thuật hoặc học bổng đúng đối tượng.

Mục tiêu & Câu hỏi nghiên cứu trọng tâm:

Mục tiêu: Xây dựng pipeline học máy hoàn chỉnh để phân loại chính xác trạng thái học tập của sinh viên thành 3 nhóm: Bỏ học (Dropout), Đang theo học (Enrolled), và Tốt nghiệp (Graduate).

Câu hỏi nghiên cứu 1: Nhóm đặc trưng nào (nhân khẩu học, kinh tế - xã hội hay điểm số học kỳ 1 & 2) có ảnh hưởng lớn nhất đến nguy cơ bỏ học của sinh viên?

Câu hỏi nghiên cứu 2: Trong các thuật toán phân lớp kinh điển (Logistic Regression, Decision Tree, Random Forest, SVM), mô hình nào cho hiệu năng tốt nhất khi kết hợp với các kỹ thuật xử lý mất cân bằng dữ liệu?

3. Xác định bài toán Máy học

Loại bài toán: Bài toán Phân lớp đa lớp có giám sát (Supervised Multiclass Classification).

Dữ liệu đầu vào (Input X): Vector gồm 36 thuộc tính phản ánh thông tin của một sinh viên tại thời điểm nhập học và kết quả học tập sau 2 học kỳ đầu tiên (bao gồm: thông tin tuyển sinh, nhân khẩu học, yếu tố kinh tế - xã hội vĩ mô và điểm số/số tín chỉ tích lũy).

Kết quả đầu ra (Output/Target y): Biến phân loại rời rạc nhận 1 trong 3 nhãn trạng thái học tập cuối khóa:

Dropout: Sinh viên bỏ học giữa chừng.

Enrolled: Sinh viên vẫn đang tiếp tục theo học (chưa tốt nghiệp tại thời điểm thu thập dữ liệu).

Graduate: Sinh viên đã hoàn thành chương trình và tốt nghiệp thành công.

4. Mô tả dữ liệu

Nguồn dữ liệu: Kho dữ liệu học thuật UCI Machine Learning Repository (được đóng góp bởi Viện Polytechnic Portalegre, Bồ Đào Nha - tác giả Valentim Realinho và cộng sự, năm 2021).

Đường dẫn truy cập: UCI Dataset - Predict Students' Dropout and Academic Success

Quy mô dữ liệu: 4.424 mẫu (sinh viên) và 36 thuộc tính đầu vào cùng 1 biến mục tiêu (Target).

Các nhóm thuộc tính chính:

Thông tin nhân khẩu học (Demographic): Giới tính (Gender), Độ tuổi khi nhập học (Age at enrollment), Tình trạng hôn nhân (Marital status), Quốc tịch (Nationality), Sinh viên xa nhà (Displaced),...

Thông tin kinh tế - xã hội (Socio-economic): Trình độ học vấn và nghề nghiệp của bố/mẹ (Mother's/Father's qualification & occupation), Tình trạng nhận học bổng (Scholarship holder), Tình trạng nợ học phí (Debtor), Học phí đóng đúng hạn (Tuition fees up to date), Tỷ lệ thất nghiệp (Unemployment rate), Lạm phát (Inflation rate), GDP.

Thông tin tuyển sinh (Admission): Ngành học (Course), Phương thức xét tuyển (Application mode), Thứ tự nguyện vọng (Application order), Điểm đầu vào (Admission grade), Hệ đào tạo ban ngày/buổi tối (Daytime/evening attendance).

Kết quả học tập 2 học kỳ đầu (Academic path): Số học phần đăng ký, số học phần được công nhận, số học phần đánh giá, số học phần qua môn và điểm trung bình của Học kỳ 1 và Học kỳ 2 (Curricular units 1st/2nd sem credited/enrolled/evaluations/approved/grade).

Biến mục tiêu (Target) và Đặc điểm dữ liệu:

Dữ liệu sạch, không có giá trị khuyết thiếu (No missing values).

Các thuộc tính bao gồm cả biến số thực (Continuous), số nguyên (Discrete) và biến phân loại đã được mã hóa số (Categorical encoded as integers).

Mất cân bằng lớp (Imbalanced Data): Phân phối của biến mục tiêu bị mất cân bằng rõ rệt giữa 3 lớp: Graduate (2.209 mẫu ~ 49.93%), Dropout (1.421 mẫu ~ 32.12%), và Enrolled (794 mẫu ~ 17.95%).

5. Phương pháp dự kiến

Khám phá dữ liệu (Exploratory Data Analysis - EDA):

Thống kê mô tả (mean, std, min, max, quartiles) cho các biến định lượng và tần suất cho các biến định tính.

Trực quan hóa phân phối của biến mục tiêu Target và mối quan hệ giữa tình trạng đóng học phí, học bổng, điểm số học kỳ 1–2 với tỷ lệ Dropout.

Xây dựng ma trận tương quan (Correlation Heatmap) để phát hiện hiện tượng đa cộng tuyến (Multicollinearity) giữa các thuộc tính học tập ở học kỳ 1 và học kỳ 2.

Tiền xử lý dữ liệu (Data Preprocessing):

Kiểm tra ngoại lai (Outliers): Sử dụng biểu đồ Boxplot và phương pháp IQR để rà soát các giá trị bất thường ở nhóm biến điểm số và tuổi nhập học.

Mã hóa biến phân loại (Encoding): Chuyển đổi biến mục tiêu (Dropout, Enrolled, Graduate) sang dạng số qua LabelEncoder. Với các biến định danh như Course hoặc Application mode, thử nghiệm One-Hot Encoding hoặc giữ nguyên tùy dòng mô hình.

Chuẩn hóa dữ liệu (Feature Scaling): Áp dụng StandardScaler (chuẩn hóa Z-score) cho các biến liên tục đối với Logistic Regression và SVM. Quá trình fit_transform chỉ thực hiện trên tập Train và transform trên tập Validation/Test để tránh rò rỉ dữ liệu (Data Leakage).

Xử lý mất cân bằng dữ liệu: Thực nghiệm so sánh 2 chiến lược trên tập huấn luyện: kỹ thuật sinh mẫu tổng hợp SMOTE và điều chỉnh trọng số lớp (class_weight='balanced').

Xây dựng và lựa chọn đặc trưng (Feature Engineering & Selection):

Tạo đặc trưng mới: Tỷ lệ qua môn học kỳ 1 và 2 (Pass_Rate_Sem1, Pass_Rate_Sem2 = số môn đậu / số môn đăng ký), Độ chênh lệch điểm số giữa 2 học kỳ (Grade_Diff = Điểm HK2 - Điểm HK1).

Lựa chọn đặc trưng: Đánh giá mức độ quan trọng của thuộc tính bằng Feature Importance (từ Random Forest) và kiểm định ANOVA F-value / Mutual Information để loại bỏ biến nhiễu.

Lựa chọn mô hình Machine Learning so sánh:

Logistic Regression (Multinomial): Đại diện nhóm mô hình tuyến tính, làm mô hình cơ sở (Baseline model), tốc độ huấn luyện nhanh, dễ giải thích tác động qua trọng số.

Decision Tree (Cây quyết định): Đại diện mô hình phi tuyến dựa trên cấu trúc cây, trực quan hóa được các luật quyết định dẫn đến việc sinh viên bỏ học.

Random Forest (Rừng ngẫu nhiên): Thuật toán học kết hợp (Ensemble - Bagging) kết hợp nhiều cây quyết định giúp giảm phương sai, hạn chế Overfitting và xử lý tốt dữ liệu bảng nhiều thuộc tính.

Support Vector Machine (SVM): Mô hình tìm siêu phẳng phân tách với lề cực đại, kết hợp hàm nhân (Kernel RBF) giúp phân loại hiệu quả trong không gian nhiều chiều.

6. Kế hoạch thực nghiệm

Phương pháp chia dữ liệu (Data Splitting): Chia bộ dữ liệu gốc theo chiến lược Stratified Split với tỷ lệ 80% Train (3.539 mẫu) – 20% Test (885 mẫu) nhằm giữ nguyên tỷ lệ phân phối của 3 lớp. Trên tập Train (80%), áp dụng 5-Fold Stratified Cross-Validation để đánh giá độ ổn định và chọn siêu tham số.

Mô hình cơ sở (Baseline Model): Sử dụng Multinomial Logistic Regression với bộ siêu tham số mặc định trên dữ liệu chuẩn hóa cơ bản làm mốc tham chiếu.

Các độ đo đánh giá (Evaluation Metrics):

Macro-F1 Score (Độ đo chính): Trung bình cộng F1-score của 3 lớp không trọng số, đánh giá công bằng cho cả lớp thiểu số.

Recall trên lớp Dropout: Đo lường khả năng phát hiện đúng các sinh viên thực sự có nguy cơ bỏ học (hạn chế False Negative).

Accuracy & Weighted-F1: Đánh giá hiệu năng tổng thể trên toàn tập dữ liệu.

Confusion Matrix (Ma trận nhầm lẫn) & ROC-AUC (One-vs-Rest): Phân tích chi tiết các cặp lớp hay bị mô hình dự đoán nhầm lẫn.

Phương án tinh chỉnh siêu tham số (Hyperparameter Tuning): Sử dụng GridSearchCV kết hợp StratifiedKFold(n_splits=5) tối ưu theo f1_macro cho Decision

Tree (criterion, max_depth, min_samples_split), Random Forest (n_estimators, max_depth, max_features, class_weight) và SVM (C, kernel, gamma).

7. Kết quả dự kiến

Sản phẩm bàn giao:

- Báo cáo tổng kết đề tài (PDF): Trình bày đầy đủ cơ sở lý thuyết, EDA, tiền xử lý, kết quả thực nghiệm, phân tích lỗi (Error Analysis) và đánh giá Overfitting/Underfitting.
- Mã nguồn (Jupyter Notebook / Python Scripts): Tổ chức rõ ràng, tái lập được kết quả (Reproducibility), kèm file README.md hướng dẫn chạy code.
- Slide thuyết trình: Tóm tắt trực quan toàn bộ quy trình và phát hiện của nhóm.

Kết quả mong đợi: Xác lập được mô hình tối ưu đạt điểm Macro-F1 từ 0.72 – 0.78 trở lên và Accuracy trên 77%, vượt trội so với Baseline; rút ra danh sách các yếu tố tác động mạnh nhất đến nguy cơ bỏ học.

Ứng dụng minh họa (Demo Application): Xây dựng giao diện Web App bằng Streamlit cho phép nhập thông tin và kết quả học kỳ 1, 2 của sinh viên để dự đoán trạng thái học tập và cảnh báo rủi ro bỏ học.

8. Kế hoạch thực hiện

Giai đoạn	**Nội dung công việc chính**	**Thành viên phụ trách**	**Kết quả đầu ra (Deliverables)**
Giai đoạn 1: Khởi tạo & Đề xuất	Tìm hiểu bài toán, khảo sát dữ liệu từ kho UCI, thống nhất quy trình làm việc và hoàn thiện đề xuất đề tài.	Cả nhóm	Bản Proposal hoàn chỉnh.
Giai đoạn 2: Khám phá dữ liệu (EDA)	Phân tích thống kê mô tả, trực quan hóa phân phối dữ liệu, kiểm tra mối tương quan giữa các thuộc tính và biến mục tiêu.	Thành Đạt (chính), Minh Tiến	Notebook phần EDA và hệ thống biểu đồ phân tích.
Giai đoạn 3: Tiền xử lý & Tạo đặc trưng	Chuẩn hóa dữ liệu (Scaling), mã hóa biến (Encoding), xây dựng và lựa chọn đặc trưng (Feature Engineering), xử lý mất cân bằng dữ liệu (SMOTE / Class Weight) và chia tập dữ liệu tránh data leakage.	Minh Tiến, Gia Phát	Pipeline tiền xử lý chuẩn & tập dữ liệu huấn luyện/kiểm thử.

Giai đoạn	Nội dung công việc chính	Thành viên phụ trách	Kết quả đầu ra (Deliverables)
Giai đoạn 4: Huấn luyện mô hình	Xây dựng mô hình Baseline (Logistic Regression) và huấn luyện các mô hình so sánh (Decision Tree, Random Forest, SVM).	Gia Phát, Thành Đạt, Văn Hiếu, Minh Tiến	Kết quả thực nghiệm sơ bộ của 4 mô hình.
Giai đoạn 5: Tinh chỉnh & Đánh giá	Tinh chỉnh siêu tham số (Hyperparameter Tuning), đánh giá mô hình bằng các độ đo (Macro-F1, Accuracy, Confusion Matrix), phân tích lỗi và đánh giá Overfitting/Underfitting.	Cả nhóm phối hợp	Bảng tổng hợp kết quả so sánh cuối cùng & phân tích chuyên sâu.
Giai đoạn 6: Đóng gói & Báo cáo	Xây dựng ứng dụng minh họa (Web App Demo), hoàn thiện báo cáo cuối kỳ, chuẩn hóa Source Code kèm README và thiết kế Slide thuyết trình.	Văn Hiếu, Gia Phát & Cả nhóm (Báo cáo)	Toàn bộ sản phẩm cuối kỳ (Report, Source Code, Slide, Demo).

9. Tài liệu tham khảo

Realinho, V., Machado, J., Baptista, L., & Martins, M. V. (2021). Predict Students' Dropout and Academic Success [Dataset]. UCI Machine Learning Repository. https://doi.org/10.24432/C5MC89

Martins, M. V., Tolledo, D., Machado, J., Baptista, L. M., & Realinho, V. (2021). Early Prediction of Student's Performance in Higher Education: A Case Study. In Trends and Applications in Information Systems and Technologies (WorldCIST 2021), Advances in Intelligent Systems and Computing, vol 1365. Springer, Cham.

Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic Minority Over-sampling Technique. Journal of Artificial Intelligence Research, 16, 321–357.

Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825–2830.